

Toss NEXT ML CHALLENGE: 광고 클릭 예측(CTR) 모델 개발 보고서

승실대학교 산업정보시스템공학과
김민중(MJoong, Private 23th)

I. 서론: 대규모 광고 클릭 데이터에 대한 접근 전략

1.1. 문제 정의 및 도전 과제

본 보고서는 "Toss NEXT ML CHALLENGE"에서 Private Leaderboard 기준 23위를 달성하여 본선에 진출한 광고 클릭 예측(Click-Through Rate, CTR) 모델의 개발 전 과정을 상세히 기술한다. 대회 핵심 과제는 사용자에게 노출된 광고가 클릭될지 여부를 예측하는 이진 분류 문제로, 주어진 대규모 사용자 로그 및 광고 속성 데이터를 기반으로 정교한 예측 모델을 구축하는 것이 목표였다.

제공된 데이터셋은 실제 산업 환경에서 마주할 수 있는 복합적인 도전 과제들을 내포하고 있었다. 첫째, 데이터의 방대한 규모(Massive Scale)가 가장 큰 제약 조건이었다. 학습 데이터인 train.parquet 파일은 총 10,704,179개의 샘플과 119개의 컬럼으로 구성되어, 모델 학습 및 피처 엔지니어링 과정에서 상당한 계산 비용과 메모리 자원을 요구했다. 둘째, 타겟 변수인 clicked 컬럼에서 나타나는 극심한 클래스 불균형(Severe Class Imbalance)은 모델이 다수 클래스(클릭하지 않음, 0)에 편향되어 소수 클래스(클릭함, 1)에 대한 예측 성능이 저하될 위험을 안고 있었다. 이는 CTR 예측 문제의 고전적인 난제 중 하나이다. 셋째, 데이터는 고차원의 이기종 피처(High-Dimensional, Heterogeneous Features)로 구성되어 있었다. gender, age_group과 같은 범주형 피처, day_of_week, hour와 같은 시계열 피처, 그리고 의미가 명확히 공개되지 않은 l_feat_*, feat_*, history_* 등 다수의 고유값(high-cardinality)을 갖는 피처들이 혼재했다. 특히, 사용자의 서버 로그 시퀀스를 담고 있는 seq 컬럼은 그 자체로 방대한 정보를 포함하고 있어 처리 및 활용이 매우 까다로웠다. 이러한 복합적인 문제들은 효율적인 데이터 처리, 정교한 피처 엔지니어링, 그리고 강력한 모델링 전략을 통합적으로 요구했다.

1.2. 전략적 방향성: 부스팅 트리의 선택과 가설

대회 주최 측에서 딥러닝(Deep Learning, DL) 기반의 모델을 베이스라인으로 제시했음에도 불구하고, 본 프로젝트는 초기부터 의도적으로 다른 전략적 방향을 설정했다. 핵심 전략은 경사 부스팅 트리(Gradient Boosting Tree Models, GBMs) 계열의 모델, 특히 LightGBM을 중심으로 모델을 구축하고 발전시키는 것이었다.

이러한 결정의 표면적인 이유는 LightGBM이 대용량 테이블 형식 데이터(tabular data)에 대해 보여주는 탁월한 학습 속도와 효율성이었다. 제한된 시간과 자원 내에서 수많은 실험을 반복해야 하는 머신러닝 대회의 특성상, 빠른 반복(iteration)은 성공의 핵심 요소이기 때문이다.

그러나 이 전략의 기저에는 더 깊은 가설, 즉 **피처 엔지니어링의 투자수익률(ROI) 가설**이 자리 잡고 있었다. 이 가설은 본 데이터셋의 특성상, 복잡한 신경망 아키텍처를 탐색하는 것보다 도메인 지식과 데이터 특성에 기반한 정교한 피처 엔지니어링에 자원을 집중하는 것이 모델 성능 향상에 더 높은 투자수익률을 가져다줄 것이라는 믿음이었다. 이 결정은 모델 중심(model-centric) 접근법보다 데이터 중심(data-centric) AI 원칙에 무게를 둔 전략적 선택이었다. 딥러닝 모델은 이미지나 텍스트와 같은 비정형 데이터로부터 특징 표현(representation)을 자동 학습하는 데 강점을 보이지만, 다수의 범주형 및 희소 피처를 포함하는 테이블 데이터에서는 트리 기반 모델이 가진 명시적인 축-평행 결정 경계(axis-parallel decision boundaries)와 피처 상호작용 메커니즘이 더 효과적으로 신호를 포착하는 경우가 많다. 따라서 시간의 주기성, 사용자-광고지면 간의 상호작용 등 도메인 지식을 직접적으로 인코딩하는 고품질 피처를 생성하는 것이 GBMs의 성능을 극대화하는 가장 직접적인 경로라고 판단했다. 이 접근법은 또한 딥러닝의 "블랙박스"적인 특성과 비교하여 개발 과정에서 더 높은 통제력과 해석 가능성을 제공한다는 장점도 있었다.

1.3. 보고서의 구조

본 보고서는 모델 개발 과정을 논리적이고 반복적인 여정으로 구성하여 서술한다. 2장에서는 LightGBM을 이용한 베이스라인 모델 구축 과정을 설명하고, 3장에서는 데이터 탐색을 통해 얻은 통찰과 이를 바탕으로 구축한 고성능 피처 엔지니어링 파이프라인 및 최종 선정된 피처들을 상세히 다룬다. 4장에서는 단일 모델의 성능을 극한으로 끌어올리기 위한 최적화 과정을, 5장에서는 성능의 한계를 돌파하기 위해 도입한 앙상블 전략과 그 발전 과정을 기술한다. 6장에서는 최종 모델의 아키텍처와 집중적인 하이퍼파라미터 튜닝 과정을 공개하며, 마지막 7장에서는 프로젝트 전체를 요약하고 성공 요인 분석 및 향후 개선 방향을 제시하며 마무리한다.

II. 부스팅 트리 기반의 베이스라인 구축 및 초기 검증

2.1. 모델 선정: LightGBM

프로젝트의 초기 베이스라인 모델로는 XGBoost, CatBoost 등 여러 GBM 계열의 알고리즘 중에서 LightGBM을 선택했다. 이러한 결정은 대규모 데이터셋을 다루는 데 있어 LightGBM이 갖는 뚜렷한 아키텍처상의 이점에 근거했다.

첫째, LightGBM은 히스토그램 기반 알고리즘(Histogram-based Algorithm)을 사용하여 연속형 피처를 이산적인 구간(bin)으로 분할한다. 이는 최적의 분할 지점을 탐색하는 과정에서 데이터 정렬에 필요한 비용을 크게 줄여주며, 메모리 사용량을 절감하고 학습 속도를 획기적으로 향상시킨다. 1,000만 개가 넘는 샘플을 다루어야 하는 본 대회 환경에서 이는 필수적인 특성이었다.

둘째, LightGBM은 전통적인 레벨 단위(level-wise) 트리 성장 방식을 사용하는 XGBoost와 달리, **리프 단위(leaf-wise) 트리 성장 방식**을 채택한다. 이 방식은 트리의 깊이가 깊어지기 전에 손실(loss)을 가장 크게 줄일 수 있는 리프 노드를 우선적으로 분할한다. 이로 인해 동일한 트리 개수(iterations) 대비 더 낮은 손실 값에 빠르게 수렴하는 경향이 있으며, 종종 더 높은 정확도를 달성한다. 물론, 이는 과적합(overfitting)의 위험을 수반하지만, max_depth, num_leaves와 같은 하이퍼파라미터를 통해 효과적으로 제어할 수 있다. 이러한 특성들은 제한된 시간 내에 신속한 실험과 모델 검증을 반복해야 하는 대회 환경에 가장 적합한 선택지로 LightGBM을 부각시켰다.

2.2. 베이스라인 모델 설계 및 성능

첫 번째 베이스라인 모델은 문제의 복잡성을 단계적으로 해결하기 위한 실용적인 접근법에 따라 설계되었다. 모델의 입력 피처로는 제공된 전체 컬럼 중, 그 크기와 복잡성으로 인해 초기 분석이 어려운 seq 컬럼을 의도적으로 제외한 나머지 모든 피처를 사용했다. 이는 방대한 시퀀스 데이터 처리라는 난제를 잠시 보류하고, 다른 피처들만으로 달성 가능한 성능의 기준점을 명확히 설정하기 위함이었다.

이 베이스라인 모델은 전체 train.parquet 데이터를 사용하여 학습되었으며, 그 결과 준수한 성능을 기록했다. 이 초기 결과는 두 가지 중요한 전략적 목적을 달성했다. 첫째, GBM 기반 접근법이 본 데이터셋에 대해 유효하고 강력한 성능을 발휘할 수 있다는 핵심 가설을 성공적으로 검증했다. 이는 딥러닝 베이스라인에서 벗어나 GBM에 집중하기로 한 초기 전략적 결정이 올바른 방향이었음을 실증적으로 뒷받침했다. 둘째, 이 모델의 성능은 이후 진행될 모든 피처 엔지니어링, 하이퍼파라미터 튜닝, 앙상블 기법 등의 효과를 정량적으로 측정하고 비교할 수 있는 필수적인 내부 벤치마크, 즉 과학적 통제군(scientific control)으로서의 역할을 수행했다. 이 기준점이 있었기에, 수많은 실험 속에서 어떤 시도가 실제로 모델 성능에 긍정적인 영향을 미치는지 객관적으로 판단하고, 체계적인 모델 개선을 이어나갈 수 있었다.

III. 데이터 탐색 및 고성능 피처 엔지니어링 파이프라인

3.1. 탐색적 데이터 분석(EDA) 핵심 발견

본격적인 피처 엔지니어링에 앞서 수행된 탐색적 데이터 분석(Exploratory Data Analysis, EDA)은 모델의 성능을 좌우할 핵심적인 통찰을 제공했다.

가장 먼저 확인된 것은 **클래스 불균형**의 심각성이었다. clicked 타겟 컬럼의 분포를 정량적으로 분석한 결과, 클릭된 샘플(positive class)의 비율이 1.9%로 극히 낮은 것으로 나타났다. 이는 모델 평가 지표로 단순 정확도(Accuracy)가 아닌, 대회의 공식 평가 산식을 기준으로 삼아야 함을 명확히 했다. 예선 리더보드는 예측 확률에 대한 평균 정밀도 점수인 AP (Average Precision)와 클래스 불균형을 보정한 WLL (Weighted LogLoss)을 50:50으로 가중 평균한 복합 지표($\text{Score} = 0.5 * \text{AP} + 0.5 * 1/(1 + \text{WLL})$)를 사용했다. 이 지표는 클릭 예측의 정밀도와 확률 보정의 정확성을 동시에 측정하므로, 모든 피처 엔지니어링과 모델 검증 과정에서 이 공식 점수를 최적화하는 것을 목표로 삼았다. 또한, 클래스 불균형은 scale_pos_weight와 같은 파라미터 튜닝을 통해 직접적으로 다루어야 할 핵심 과제를 시사했다.

두 번째 중요한 발견은 **결측치의 패턴**이었다. 데이터 내 결측치들이 무작위로 발생한 것이 아니라 특정 패턴을 보인다는 점을 포착했다. 이는 결측 자체가 중요한 정보를 담고 있을 가능성을 의미했다. 현실 세계의 데이터셋에서는 데이터 수집 과정의 특성상 특정 조건 하에서만 값이 기록되거나 누락되는 경우가 빈번하다. 예를 들어, 특정 유형의 광고나 사용자 세그먼트에만 적용되는 피처는 그 외의 경우에는 결측치로 남게 된다. 만약 결측이 무작위적이라면 평균값이나 중앙값 등으로 대체하는 것이 합리적일 수 있으나, 이처럼 체계적인 패턴을 보인다면 값의 부재(absence) 자체가 하나의 독립적인 신호로 작용할 수 있다. 하지만 feat_e_3 컬럼에서는 다른 변수들과 구분되는 결측 패턴이 확인되었고, 이는 해당 피처의 결측 여부를 나타내는 이진 피처(binary feature)를 생성하는 전략으로 이어졌다. 트리 기반 모델은 이러한 이진 피처를 분기 노드에서 효과적으로 활용하여, 결측이 의미하는 특정 데이터의 하위 그룹을 분리해낼 수 있다.

3.2. 신속한 실험을 위한 검증 파이프라인 설계

수백, 수천 가지의 피처 아이디어를 효율적으로 검증하기 위해서는 신속하고 신뢰성 있는 실험 파이프라인의 구축이 필수적이었다. 전체 1,000만 건의 데이터를 매번 학습시키는 것은 비효율적이었기에, 실험의 속도와 검증의 신뢰도 사이의 균형을 맞추기 위한 정교한 이중 검증 파이프라인(dual-validation pipeline)을 설계했다.

구성 요소 1: 1:5 비율의 비중복 언더샘플링 데이터 (1:5 Non-Overlapping Undersampled Data)

- **방법:** 모든 포지티브 샘플(clicked=1)을 유지하면서, 네거티브 샘플(clicked=0) 중에서 5배수만큼을 무작위로 추출하여 작은 크기의 데이터셋을 생성했다. 교차 검증(cross-validation) 시 폴드(fold) 간 데이터 중복이 없도록 설계하여 평가의 신뢰성을 확보했다.
- **목적:** 이 데이터셋은 계산 시간을 극적으로 단축시켜, 다양한 피처 아이디어를 빠르게 테스트하고 효과를 1차적으로 스크리닝하는 역할을 수행했다. 이를 통해 하루에도 수십 개의 피처 조합을 실험할

수 있는 높은 실험 처리량을 확보했다.

구성 요소 2: 100만 건 규모의 층화추출 데이터 (1M Stratified Sampled Data)

- **방법:** 원본 test.parquet 데이터의 clicked 분포와 동일한 비율을 유지하도록 층화추출(stratified sampling)하여 100만 건 규모의 검증용 데이터셋을 생성했다.
- **목적:** 이 데이터셋은 "카나리아(canary)" 데이터셋으로서, 언더샘플링 데이터에서 유효성을 보인 피처들이 실제 테스트 환경과 유사한 분포에서도 일반화 성능을 유지하는지 최종적으로 확인하는 역할을 했다. 이 단계를 통과한 피처만이 전체 데이터를 사용한 최종 모델 학습에 포함될 가능성이 높아졌다.

단순히 속도만을 추구한 것이 아니라, 실험 속도와 검증 신뢰도 간의 트레이드오프(trade-off)를 체계적으로 관리하였다. 1단계(언더샘플링)에서 수많은 아이디어를 광범위하고 신속하게 걸러내고, 2단계(층화추출)에서 1단계를 통과한 유망한 피처들을 더 엄격하고 현실적인 조건에서 재검증하는 2단계 검증 프로세스를 구축했다. 이를 통해 잠재적으로 과적합을 유발하거나 일반화 성능이 낮은 피처를 조기에 탈락시키고, 진짜 유용한 피처를 찾아내는 데 자원을 집중함으로써 개발 효율성을 극대화했다.

3.3. 최종 선정 피처 및 그 효과

위에서 설명한 엄격한 검증 파이프라인을 통해 수많은 피처 아이디어가 생성되고 폐기되는 과정을 거쳤다. 지나치게 세분화된 상호작용 피처나 seq 로그에서 발견된 특정 패턴을 직접 적용하는 등의 복잡한 시도들은 대부분 성능 향상에 기여하지 못하거나 오히려 성능을 저하시켰다. 이는 모델의 일반화 가능성을 해치는 과적합을 유발했기 때문으로 분석된다. 오랜 실험 끝에, 꾸준히 안정적인 성능 향상을 보인 약 15개의 핵심 피처들이 최종적으로 선정되었다. 이 피처들은 Global Optimal은 아닐지라도, 주어진 데이터와 모델 하에서 도달한 지역 최적(local optimum)의 조합이라고 판단되었다.

최종 선정된 핵심 피처들은 다음과 같이 요약할 수 있다.

표 1: 최종 선정 피처 요약 및 설명

피처 카테고리	피처 이름/설명	가설 및 근거
시퀀스 통계 (Sequence Statistics)	seq 컬럼의 평균, 표준편차, 최대값, 최소값	사용자의 활동성(engagement) 수준을 나타내는 지표. 시퀀스가 길거나 다양한 아이템을 포함할수록 더 활동적인 사용자일 가능성이 높다.
과거 인기도 통계 (History)	inventory_id로 그룹화한	특정 광고 지면(inventory)에

Statistics)	history_a_* 컬럼들의 평균/표준편차/최대값	노출되었던 과거 광고들의 인기도(클릭률 등)를 집계하여, 현재 광고의 성과를 예측하는 데 활용한다.
시간 상호작용 (Temporal Interaction)	hour와 day_of_week의 조합 피쳐	'월요일 오전 출근 시간'이나 '금요일 저녁'과 같이 특정 요일과 시간대가 결합될 때 나타나는 고유한 트래픽 패턴을 포착한다.
시간 주기성 (Temporal Periodicity)	sin(hour), cos(hour), sin(day), cos(day)	시간 데이터의 순환적 특성을 모델에 인코딩한다. 예를 들어, 23시가 0시와 가깝다는 관계를 모델이 학습할 수 있도록 돕는다.
범주형 상호작용 (Categorical Interaction)	inventory_id와 age_group의 조합 피쳐	특정 광고 지면이 특정 연령대의 사용자 그룹에게 유독 더 효과적이거나 비효과적일 수 있다는 가설을 검증한다.
결측 여부 (Missingness Indicator)	feat_e_3_is_null (이진 피쳐)	feat_e_3 값의 부재 자체가 예측에 유용한 신호로 작용한다. 이는 특정 광고 유형이나 사용자 맥락을 나타낼 가능성이 있다.

또한, inventory_id와 같이 고유값이 매우 많은 범주형 피쳐나 상호작용 피쳐에 대해서는 **Out-of-Fold (OOF) 타겟 인코딩** 기법을 적용했다. 이 기법은 교차 검증 시 현재 폴드(fold)를 제외한 나머지 폴드들의 타겟 변수 평균값으로 범주를 대체하는 방식이다. 이를 통해 타겟 변수의 정보를 피쳐로 활용하면서도 타겟 누수(target leakage)를 효과적으로 방지하여 강력한 예측 성능을 확보할 수 있었다.

IV. 단일 모델 성능 최적화: LightGBM 심층 튜닝

4.1. 클래스 불균형 대응 전략

피처 엔지니어링을 통해 모델의 기본 성능을 향상시킨 후, 데이터의 근본적인 문제인 클래스 불균형에 보다 직접적으로 대응하는 전략을 채택했다. 데이터 레벨에서 언더샘플링을 사용하는 대신, 최종 모델 학습 단계에서는 모델 레벨의 접근법인 LightGBM의 `scale_pos_weight` 파라미터를 활용했다.

이 파라미터는 손실 함수(loss function) 계산 시 소수 클래스(positive samples, `clicked=1`)에 더 높은 가중치를 부여하는 역할을 한다. 예를 들어, `scale_pos_weight` 값을 10으로 설정하면, 모델은 포지티브 샘플 하나를 잘못 분류했을 때 네거티브 샘플 10개를 잘못 분류한 것과 유사한 페널티를 받게 된다. 이로 인해 모델은 소수 클래스를 올바르게 분류하는 데 더 많은 노력을 기울이게 되며, 결과적으로 재현율(Recall)과 AUC 성능이 향상될 수 있다. 이 방법은 데이터 샘플을 인위적으로 제거하거나 복제하지 않으면서도 불균형 문제를 효과적으로 완화할 수 있어, 최종 모델 학습에 더 적합하다고 판단되었다.

4.2. 최종 학습 데이터 구성 및 하이퍼파라미터 튜닝

단일 모델의 성능을 극한까지 끌어올리기 위해 최종 학습 데이터 구성과 하이퍼파라미터 튜닝 전략을 정교화했다.

전체 데이터 학습(Full Training) 접근법: 최종 제출 모델을 생성할 때는 검증 세트(validation set)를 따로 분리하지 않고, 따로 준비한 1:5 언더샘플링 데이터 전체를 학습에 사용하는 `full_train` 방식을 채택했다. 이는 흔히 사용되는 전략으로, 모델의 아키텍처, 피처셋, 그리고 교차 검증을 통해 찾은 최적의 하이퍼파라미터가 확정된 후에는 가용한 모든 데이터를 학습에 활용하여 모델이 최대한 많은 패턴을 학습하도록 하는 것이다. 검증 세트로 사용될 데이터를 학습에 추가로 사용함으로써, 일반적으로 미미한 성능 향상을 기대할 수 있다.

초기 하이퍼파라미터 최적화: 하이퍼파라미터 튜닝에는 최신 베이지안 최적화(Bayesian Optimization) 프레임워크인 Optuna를 사용했다. 초기 단계에서는 약 10회의 시도(trial)만으로 제한적인 탐색을 수행했다. 이 단계의 목표는 전역 최적점(global optimum)을 찾는 것이 아니라, 기본 설정값(default configuration) 상태의 모델을 합리적인 시간 내에 "강력하게 튜닝된" 상태로 신속하게 전환하는 것이었다. 이를 통해 효율적으로 성능을 개선하고, 이후 더 복잡한 앙상블 모델을 탐색하기 위한 견고한 기반을 마련했다.

V. 앙상블 전략의 도입 및 가중치 최적화

5.1. 성능 한계 돌파를 위한 앙상블 도입

정교한 피처 엔지니어링과 심층적인 하이퍼파라미터 튜닝을 통해 단일 LightGBM 모델의 성능은 특정 수준에 도달한 후 더 이상 개선되지 않는 성능 포화 상태, 즉 한계점(plateau)에 도달했다. 이러한 한계를 돌파하기 위한 전략으로 모델 앙상블(ensemble) 기법을 도입했다.

앙상블의 핵심은 서로 다른 강점을 가진 여러 모델의 예측을 결합하여 단일 모델보다 더 강건하고 정확한 예측을 만들어내는 것이다. 이를 위해 기존의 LightGBM 모델에 더해, GBM 계열의 또 다른 강력한 모델인 XGBoost와 CatBoost를 추가했다. 세 모델은 모두 부스팅 트리라는 공통점을 가지지만, 내부적인 작동 방식에는 중요한 차이점이 존재한다. XGBoost는 레벨 단위 트리 성장과 강력한 정규화(regularization) 기능을 특징으로 하며, CatBoost는 순서 기반 부스팅(ordered boosting)과 범주형 피처를 자동으로 처리하는 탁월한 능력으로 잘 알려져 있다. 이러한 구조적 차이로 인해 각 모델은 데이터의 서로 다른 측면을 학습하게 되며, 이들의 예측을 결합했을 때 개별 모델의 약점은 상쇄되고 강점은 강화되는 시너지 효과가 발생한다.

초기 앙상블은 각 모델의 예측 확률값을 단순 평균(simple average)하는 방식으로 시도되었으며, 그 결과 리더보드 점수가 꽤 많이 오르는 즉각적이고 상당한 성능 향상을 확인할 수 있었다. 이는 앙상블 전략의 유효성을 명백히 입증하는 결과였다.

5.2. 개별 모델 성능 분석 및 가중 앙상블로의 전환

단순 평균 앙상블의 성공에 안주하지 않고, 앙상블의 효율을 극대화하기 위해 각 개별 모델의 성능을 심층적으로 분석하는 실험을 진행했다. LightGBM, XGBoost, CatBoost 모델을 각각 동일한 피처셋과 최적화 과정을 거쳐 독립적으로 학습시키고, 대회의 공식 평가 산식에 따른 리더보드 점수를 기준으로 그 성능을 비교했다.

이 과정에서 결정적인 발견이 이루어졌다. 새로 도입한 XGBoost 모델이 최적화 이후, 프로젝트 초기부터 공들여 튜닝해 온 LightGBM 모델보다 월등히 높은 단독 성능을 보인다는 사실을 확인한 것이다. 이는 앙상블 전략을 한 단계 더 발전시키는 중요한 계기가 되었다.

표 2: 개별 모델 성능 비교 (공식 평가 점수)

모델 (Model)	최적화 후 공식 평가 점수 (Optimized Official Score)
LightGBM	Final Score: 0.3544 (AP: 0.0810, WLL:

	0.5949)
XGBoost	Final Score: 0.3550 (AP: 0.0830, WLL: 0.5949)
CatBoost	Final Score: 0.3545 (AP: 0.0818, WLL: 0.5949)

위 표와 같은 실험 결과는 앙상블 내에서 각 모델의 기여도가 동등하지 않음을 명확히 보여주었다. 따라서 모든 모델에 동일한 가중치를 부여하는 단순 평균 방식보다, 성능이 더 우수한 모델에 더 높은 가중치를 부여하는 **가중 평균(weighted average) 앙상블**이 더 합리적이라는 결론에 도달했다. 예측 확률값 $P_{\{LGBM\}}$, $P_{\{XGB\}}$, $P_{\{CAT\}}$ 에 대해, 최종 예측 $P_{\{final\}}$ 을 $P_{\{final\}} = \{P_{\{LGBM\}} + P_{\{XGB\}} + P_{\{CAT\}}\} / 3$ 와 같이 계산하는 대신, $P_{\{final\}} = w_1 * P_{\{LGBM\}} + w_2 * P_{\{XGB\}} + w_3 * P_{\{CAT\}}$ (단, $w_1 + w_2 + w_3 = 1$)와 같이 가중치를 적용했다. 이때, 단독 성능이 가장 높았던 XGBoost에 가장 높은 가중치(w_2)를 부여하는 방식으로 앙상블 공식을 수정했으며, 이는 추가적인 성능 향상으로 이어졌다. 이 과정은 경험적 데이터에 기반하여 모델링 전략을 적응적으로 수정해나가는 체계적인 접근법의 중요성을 보여준다.

5.3. 실패한 실험: 딥러닝 모델과의 앙상블

GBM 기반 앙상블의 성능이 한계에 가까워졌다고 판단했을 때, 모델 다양성을 극대화하기 위해 딥러닝 모델과의 앙상블을 시도했다. 이를 위해 새로운 데이터 처리 파이프라인을 구축하고 딥러닝 모델을 학습시켜 기존의 트리 모델 앙상블에 결합했다.

그러나 이 실험은 리더보드에서 좋지 못한 성적을 기록하며 실패로 돌아갔다. 이 결과는 단순한 실패가 아니라, 프로젝트 초기에 세웠던 **핵심 가설을 검증하는 중요한 과정**이었다. 본 데이터셋에서는 정교한 피처 엔지니어링과 GBM의 조합이 복잡한 딥러닝 아키텍처보다 우월할 것이라는 가설이 실제 실험을 통해 다시 한번 확인된 것이다. 이 경험을 통해, 무분별하게 모델의 종류를 늘리는 것보다 이미 성능이 검증된 접근법에 자원을 집중하고 완성도를 높이는 것이 경쟁 환경에서 더 효과적이라는 교훈을 얻었다. 결국 이 실험을 기점으로 딥러닝 모델을 과감히 포기하고, 세 개의 부스팅 트리 모델(LightGBM, XGBoost, CatBoost)의 성능을 개별적으로 그리고 종합적으로 극한까지 끌어올리는 데 모든 노력을 집중하기로 최종 결론 내렸다.

VI. 최종 모델 아키텍처 및 하이퍼파라미터 최적화

6.1. 최종 모델 아키텍처

최종 제출 모델은 개별적으로 최적화된 LightGBM, XGBoost, CatBoost 세 모델의 예측 결과를 가중 평균하여 결합한 앙상블 모델로 확정되었다. 각 모델은 동일한 최종 피처셋을 입력으로 사용하지만, 고유의 알고리즘적 특성으로 인해 데이터의 다른 측면을 학습하여 상호 보완적인 예측을 생성한다.

또한, 최종 모델의 안정성을 높이기 위해 일부 수치형 피처에 대해 이상치 클리핑(outlier clipping)과 같은 미세 조정을 적용했다. 이는 학습 과정에서 극단적인 값들이 모델에 과도한 영향을 미치는 것을 방지하여, 예측의 강건성을 소폭 향상시키는 효과를 가져왔다.

6.2. 최종 하이퍼파라미터 최적화 캠페인

대회 막바지, 모델의 성능을 한 방울까지 짜내기 위한 집중적이고 공격적인 최종 하이퍼파라미터 최적화 캠페인을 진행했다. 이는 각 개별 모델의 잠재력을 최대치로 끌어올려 앙상블의 전체 성능을 극대화하기 위한 마지막 단계였다.

탐색 범위 확대: Optuna를 이용한 최적화 시도 횟수(trial)를 각 모델당 20회로 늘려, 하이퍼파라미터 공간을 이전보다 훨씬 더 광범위하고 철저하게 탐색했다.

공격적인 파라미터 범위 설정:

- **학습률 (Learning Rate):** 0.05에서 0.2 사이의 비교적 높은 범위를 탐색하도록 설정했다.
- **부스팅 라운드 수 (Number of Estimators):** num_boost_round (CatBoost의 경우 iterations)를 3000 이상으로 설정하고, 특히 가장 성능이 좋았던 XGBoost에 대해서는 6000이라는 매우 높은 값을 허용했다.

이러한 **높은 학습률과 많은 부스팅 라운드의 조합**은 의도된 전략이었다. 이는 모델이 매우 복잡하고 강력한 패턴을 학습하도록 유도하는 고위험 고수익(high-risk, high-reward) 접근법이다. 낮은 학습률과 많은 부스팅 라운드는 모델이 조심스럽고 안정적으로 수렴하도록 돕는 반면, 높은 학습률과 많은 부스팅 라운드는 모델이 학습 데이터에 매우 공격적으로 적합(fit)하도록 만든다. 단일 모델에 적용할 경우 과적합의 위험이 매우 크지만, 본 프로젝트와 같이 규모가 크고 복잡한 데이터셋에서는 미세한 신호까지 포착하여 최고의 성능을 달성하기 위해 필요한 전략일 수 있다. 최종적으로 세 개의 서로 다른 모델이 각각 이러한 방식으로 고도로 복잡해지면, 각 모델이 가진 특유의 과적합 편향이 앙상블 과정에서 서로 상쇄되고 평균화된다. 그 결과, 개별적으로는 과적합 위험이 높지만 전체적으로는 강건하면서도 극도로 강력한 최종 예측 모델이 탄생하게 된다. 이는 대회의 순위 경쟁에서 마지막 한 걸음을 내딛기 위한 최종적인 성능 압착(performance squeeze) 전략이었다.

6.3. 최종 하이퍼파라미터

집중적인 Optuna 최적화 캠페인을 통해 도출된 최종 앙상블 모델의 핵심 하이퍼파라미터는 다음과 같다. 이 값들은 본 프로젝트의 재현성과 기술적 투명성을 위해 상세히 기록되었다.

표 3: 최종 앙상블 모델 하이퍼파라미터

모델 (Model)	파라미터 (Parameter)	최종 값 (Final Value)
LightGBM	learning_rate	0.027357360985606104
	num_leaves	94
	max_depth	12
	min_child_samples	56
	subsample	0.7355028193733041
	colsample_bytree	0.5020780377426634
	reg_alpha	1.3450748035440614
	reg_lambda	0.8851408162033914
XGBoost	objective	'binary:logistic'
	eval_metric	'auc'
	tree_method	'gpu_hist'
	max_depth	10
	learning_rate	0.006229765764527009

	subsample	0.7765182233835292
	colsample_bytree	0.573556750803278
	min_child_weight	45
	gamma	0.685398998466496
	reg_alpha	0.38488409751539265
	reg_lambda	0.5173731295762696
	scale_pos_weight	scale_pos_weight_value
	random_state	42
	verbosity	1
CatBoost	loss_function	'Logloss'
	eval_metric	'AUC'
	depth	9
	learning_rate	0.015887402428557403
	l2_leaf_reg	1.5283126467878267
	bagging_temperature	0.7572280338208215
	subsample	0.5651908745011828
	min_child_samples	92
	scale_pos_weight	scale_pos_weight_value
	random_state	42

	iterations	2990
	verbose	100

VII. 결론 및 성찰

7.1. 프로젝트 요약 및 성과

본 프로젝트는 Toss NEXT ML CHALLENGE의 광고 클릭 예측 과제를 해결하기 위해, 부스팅 트리 모델을 중심으로 한 데이터 중심적 접근법을 채택했다. 딥러닝 베이스라인에서 벗어나 LightGBM을 초기 모델로 선정하고, 신속한 실험을 위한 이중 검증 파이프라인을 구축하여 체계적인 피처 엔지니어링을 수행했다. 이를 통해 약 15개의 고성능 피처를 발굴하고 단일 모델의 성능을 극대화했다. 이후 성능 한계를 돌파하기 위해 XGBoost와 CatBoost를 도입한 앙상블 전략으로 전환했으며, 개별 모델 성능 분석에 기반한 가중 평균 방식을 채택하여 앙상블 효율을 최적화했다. 최종적으로 각 모델에 대한 집중적인 하이퍼파라미터 튜닝을 통해 모델의 잠재력을 극한까지 끌어올렸다.

이러한 체계적이고 반복적인 개발 과정을 통해 구축된 최종 앙상블 모델은 Private Leaderboard 기준 23위를 달성하는 성과를 거두었으며, 이를 통해 본선 진출 자격을 획득했다. 이는 본 프로젝트에서 수립한 전략과 방법론의 유효성을 성공적으로 입증한 결과이다.

7.2. 성공의 핵심 요인

본 프로젝트의 성공은 다음 네 가지 핵심 요인에 기인한 것으로 분석된다.

- 원칙에 기반한 데이터 중심 전략 (A Principled, Data-Centric Strategy):** 프로젝트 초기에 데이터의 특성을 분석하여, 모델의 복잡성보다는 피처 엔지니어링의 중요성이 더 높을 것이라는 정확한 가설을 수립했다. 이 데이터 중심적 접근법은 프로젝트 전반의 방향을 결정하고 자원을 효율적으로 배분하는 기준이 되었다.
- 견고하고 효율적인 검증 프레임워크 (A Robust and Efficient Validation Framework):** 언더샘플링과 증화추출을 결합한 이중 검증 파이프라인은 수많은 피처 아이디어를 신속하고 신뢰성 있게 평가할 수 있는 엔진 역할을 했다. 이 프레임워크가 엄청 높은 정확도를 보인 것은 아니었지만 만약에 없었다면, 제한된 시간 내에 고품질의 피처 조합을 발견하는 것은 불가능했을 것이다.

3. **적응적이고 증거 기반의 앙상블 방법론 (An Adaptive, Evidence-Based Ensemble Method):** 단일 모델에서 시작하여 단순 평균 앙상블, 그리고 최종적으로는 실제 성능 데이터에 기반한 가중 평균 앙상블로 점진적으로 발전시킨 과정을 통해 문제 해결에 대한 유연하고 적응적인 태도를 배울 수 있었다. 각 단계에서 얻은 경험적 증거를 바탕으로 다음 전략을 결정한 것이 중요한 것을 깨닫게 되었다.
4. **엄격하고 집중적인 최종 최적화 (Rigorous and Intensive Final Optimization):** 마지막 단계에서 수행된 공격적인 하이퍼파라미터 튜닝은 모델의 성능을 마지막 한 방울까지 짜내는 데 결정적인 역할을 했다. 이는 경쟁 환경에서 미세한 성능 차이가 순위를 결정짓는다는 점을 고려한 필수적인 과정이었다.

7.3. 향후 개선 방향 및 성찰

본 대회 기간 동안 성공적인 결과를 얻었지만, 추가적인 시간이 주어진다면 다음과 같은 방향으로 모델을 더욱 개선할 수 있을 것이다.

- **고급 피처 선택 기법:** 현재는 실험적으로 유효한 피처들을 조합했지만, 순열 중요도(Permutation Importance)나 SHAP(SHapley Additive exPlanations) 값을 활용하여 피처 간의 상호작용을 고려한 체계적인 피처 선택(feature selection)을 시도해볼 수 있다.
- **다양한 앙상블 기법:** 현재 사용한 가중 평균 방식 외에, 각 모델의 예측값을 다시 피처로 사용하여 메타 모델(meta-model)을 학습시키는 스택킹(Stacking) 앙상블을 구축하면 추가적인 성능 향상을 기대할 수 있다.
- **딥러닝 모델의 성공적인 통합:** 이번 실험에서는 실패했지만, seq와 같은 시퀀스 데이터나 임베딩이 필요한 고차원 범주형 피처 처리에 특화된 딥러닝 모델(예: Transformer, DCN)을 설계하여 GBM 모델과 효과적으로 앙상블하는 방안을 재탐색해 볼 가치가 있다.

이번 대회를 통해, 성공적인 머신러닝 프로젝트는 단순히 최신 알고리즘을 적용하는 것을 넘어, 문제에 대한 깊은 이해를 바탕으로 데이터 처리, 피처 엔지니어링, 모델링, 검증에 이르는 전 과정을 유기적으로 설계하고 끊임없이 개선해나가는 과정임을 다시 한번 확인할 수 있었다.